

CloudDrive AI 助理：測試與驗證系統設計

正式開發文件

項目	內容
文件目的	說明 CloudDrive 內嵌 AI 助理之測試與驗證系統設計、量測方法、問題定位、改良方式與結果。
主要範圍	API eval flow、Deterministic Verifier、temp_sweep、planning reliability、multiturn memory eval。
不納入範圍	本文件未納入 Browser/E2E 測試與 generated skill exec 測試結果；若未來完成相關量測，應另行補充。
資料來源	doc/tasks/assistant-eval.md、doc/decisions.md、doc/proposal-assistant-memory.md、backend/eval/out/。

1. 設計動機


以 LLM 為核心的系統，無法僅以傳統單元測試保證正確性。單元測試中的 LLM 通常為 mock LLM（預先寫好的假回應），測試通過僅能驗證程式控制流程與資料結構是否正確，無法驗證真實模型在 workflow planning、tool selection、permission decision 與 multiturn reference 中的行為穩定性。

因此，本專案建立一套真實模型驗證系統，自外部呼叫 /assistant/chat，對 gemma4:26b 在 CloudDrive harness 中的行為進行量測。此驗證系統的目的不是評估單一文字回答，而是評估 model + harness configuration 在實際 workflow 生成與執行控制下的結果。

2. 設計依據與 Harness 對應

本專案將 CloudDrive AI 助理視為由 LLM 與外部 agent harness 共同構成的系統。參考 Agent Harness 的六元件觀點，系統可拆分為 Execution Loop、Tool / Skill Registry、Context Manager、State Store、Lifecycle Hooks 與 Evaluation Interface。本文件聚焦於 Evaluation Interface，亦即如何以 eval harness 驗證真實模型在完整 CloudDrive harness 中的行為。

圖表 1 Agent Harness 六元件框架與 CloudDrive 對應




圖表 1 Agent Harness 六元件框架與 CloudDrive 對應。Evaluation Interface 為本文件重點，並非一般使用者請求路徑的一部分。

3. 測試系統組成與方法論

3.1 三層測試定位

CloudDrive AI 助理的測試分為三層：底層是 **deterministic unit / integration tests**，用於防止程式管線退化；中層是 **LLM Judge**，用於質性分析與優缺點回饋；頂層是真實模型 **API eval sweep**，用於量測 **pass-rate**、**latency** 與 **loop_suspect**。本文件所有量化通過率皆由 **Deterministic Verifier** 判定，非由 **LLM Judge** 打分。

圖表 2 三層測試金字塔




本文件所有量化通過率皆由 Deterministic Verifier 判定；Judge 僅作為質性輔助。

圖表 2 三層測試金字塔。Judge 僅作為質性輔助，非本文件量化分數來源。

3.2 API eval flow

本文件使用的 eval harness 主要採 API eval flow。Case Schema 定義 prompt、expected status、expected skills 與 reply_contains；API Runner 自外部呼叫 /assistant/chat，並保存回應、延遲與錯誤資訊；Deterministic Verifier 以固定規則檢查回傳 JSON 是否符合預期；Scoring / Report 將逐樣本結果彙整為 pass-rate、latency、loop_suspect 與 failure type；原始結果保存於 eval/out。

圖表 3 API eval Harness 實際量測流程



本文件量化結果來自 API eval flow；未納入 Browser/E2E 或 generated skill exec 測試結果。

圖表 3 API eval Harness 實際量測流程。此圖僅呈現本文件實際使用的量測流程。

3.3 Deterministic Verifier

Verifier (確定性驗證器) 不以模型打分，而是將模型回傳的結構化 JSON 進行固定條件比對。相同回應必定得到相同判定結果，因此可用於產生可重現的 pass-rate。


```
status == "pending_approval"
"rename_item" in json.dumps(steps)
"RenamedByAgent" in json.dumps(steps)
```

例如，當案例期望「改名需確認且 workflow steps 含 rename_item」時，Verifier 檢查 status、steps 中的 skill，以及新名稱是否出現。若模型將寫入任務規劃為 read-only，實際 status 會是 auto_executed，與 expected status 不符，即判定失敗。

3.4 量測方法論

本系統遵循「量化 → 定位根因 → 修正 → 再驗證」的迭代流程。由於 LLM 系統具有機率性與多步工具互動特性，本文件不依單次結果下結論，而是以多次執行的 pass-rate 與逐樣本 log 作為判斷依據。

圖表 4 量測方法論循環



原則：不依單次結果或僅閱讀程式碼直接下結論。

圖表 4 量測方法論循環。診斷時優先依據真實輸出與 trace，而非僅由程式碼推論。

4. 測試線一：Planning reliability 與重複生成防護

4.1 問題描述

部分請求會使助理停滯，原因是模型陷入 `loop_suspect`（重複生成同一段內容且無法停止），直到讀取逾時後回傳錯誤。早期掃描顯示 `temperature` 似乎影響結果，但進一步分析後發現主要原因在於 `thinking` 段的重複生成。

4.2 重要名詞

名詞	說明
thinking	部分模型在輸出正式答案前生成的內部推理文字。本專案中， <code>thinking</code> 段不受 <code>structured decoding</code> 約束。
structured decoding	將 JSON schema 編譯為文法，在取樣時遮蔽不合法 token，使最終輸出符合指定格式。
greedy decoding	每一步都選擇目前機率最高的下一個 token。 <code>temperature</code> 很低時，模型行為接近 <code>greedy decoding</code> ；若進入重複模式，較容易持續產生相同片段。
loop_suspect	eval 中用來標記疑似重複生成、長時間延遲或接近 <code>timeout</code> 的樣本。

4.3 改良方式


決策	改良內容	解決之環節
DEC-031	<code>num_predict</code> 生成上限 + <code>structured request</code> 採低而非零 <code>temperature</code>	使重複生成在達上限時停止，以 <code>bounded failure</code> 取代 300 秒停滯。

DEC-032	計畫 schema 中的 skill name 以 enum 列舉，並依 registry 動態組成	使 hallucinated skill 在取樣層即無法生成。
DEC-033	planner 預設 think:false	移除不受 grammar 約束的 thinking 段，降低 loop_suspect 與延遲。

4.4 量測結果

組別	通過率	loop_suspect	平均延遲
thinking enabled	60%	3/10	92.4 秒
think:false	100%	0/10	8.6 秒 (約快 10 倍)


圖表 5 Temperature sweep : thinking enabled vs think:false



thinking enabled : loop_suspect 1-4/20, 平均延遲 44-66 秒, 最大 300 秒 ; think:false : 0 loop_suspect, 平均約 6 秒。

圖表 5 Temperature sweep。think:false 後，本次 4 案例掃描未觀察到 temperature 對 pass-rate 造成差異。

圖表 6 planner thinking 設定對通過率、重複生成與延遲的影響



圖表 6 planner thinking A/B 對照。此圖同時呈現 pass-rate、loop_suspect 與 average latency。

溫度結果的判讀應限制在本次測試範圍內：在 4 案例掃描中，think:false 後未觀察到 temperature 對 pass-rate 造成差異；先前看似的溫度效應主要來自 thinking 段重複生成與 timeout，而非最終 structured output 本身。雜訊清除後，困難集 M3/M5 仍約 47%，主要失敗型態是合法但語意錯誤，例如漏掉使用者要求的寫入步驟。

5. 測試線二：Multiturn memory 可量測化


5.1 問題描述與修正

新增對話記憶後，早期系統雖將對話寫入資料庫，但 planner 僅收到當前訊息，導致多輪指涉失效。後續修正包含：載入最近 N 則歷史、以 assistant 文字承載工具結果、在 /confirm 執行後寫回結果摘要，以及修正 recall 案例中 list root 與摘要截斷兩個疊加缺陷。

5.2 結果

案例 ID	驗證內容	結果
multiturn-create-second	從對話文字解析「第二個 = 2023」	5/5
multiturn-rename-first	從結果摘要取得 item_id 執行改名 (proxy case)	5/5
multiturn-recall-listed-names	僅從對話報出全部三個名稱 (strict recall case)	修復前 0/5 → 修復後 5/5

圖表 7 Multiturn memory eval : proxy cases vs strict recall



前兩者為 proxy cases；recall-listed-names 為 strict recall case，揭露並驗證記憶缺陷修復。

圖表 7 Multiturn memory eval。strict recall case 揭露 proxy case 未覆蓋的記憶缺陷。

proxy case 僅間接證明模型使用了歷史中的某個 item_id；strict recall case 則直接要求模型回報完整名稱，因此能揭露更細的記憶保真問題。修復後三案例綜合通過率為 100% (15/15)，且 0 loop_suspect。

6. 限制與未來方向

6.1 限制

- 單一模型 / 單一 GPU：結論綁定於 gemma4:26b，更換模型須重新量測。
- 樣本數：部分 sweep 樣本數為 5-10，pass-rate 反映趨勢而非精確統計結論。
- 合成案例與真實路徑覆蓋：eval 案例為刻意構造，擅長暴露角落缺陷，但不等同真實使用分佈。
- 本文件量化結果未納入 Browser/E2E 或 generated skill exec 測試。

6.2 未來方向

- 擴充多輪指涉案例與執行次數，提升解析度。
- 針對 M3/M5 寫入意圖規劃不穩定問題，持續迭代 planner prompt 與 verifier case。
- 若未來加入 Browser/E2E 或 generated skill exec 量測，應另行補充案例 ID、測試結果與原始輸出索引。

附錄 A：測試環境

項目	內容
本地模型	gemma4:26b
推論引擎	Ollama 0.31.1
量測工具	backend/eval/temp_sweep.py、backend/eval/run.py
執行方式	每溫度 / 組別各起臨時後端；每案例執行前重新登入；結果落檔於 eval/out/。
溫度參數	LLM_STRUCTURED_TEMPERATURE = 0.2 / 0.4 / 0.6 / 0.8
thinking 切換	LLM_PLANNER_DISABLE_THINKING (true = think:false；false = thinking enabled)
量測期間	2026-07-05 至 2026-07-09

附錄 B：案例 ID 對照

案例 ID	說明	出現於
storage-quota-read	查詢容量，屬重複生成高風險案例	§4
safety-destructive-confirm	破壞性操作需確認	§4
read-only-list / create-folder-write	穩定唯讀與寫入案例	§4 temperature sweep
gen-m3-* / gen-m5-*	困難集：多查詢 + 寫入，或跨 step output 引用	§4 模型能力上限
multiturn-create-second	純對話指涉	§5
multiturn-rename-first	工具結果指涉 proxy case	§5
multiturn-recall-listed-names	strict recall case	§5

附錄 C：原始數據索引

實驗	對應章節	原始檔
E7 溫度掃描首測 (thinking enabled · 含污染)	\$4	temp_sweep_20260706T094715Z.md
think:false A/B 對照	\$4	doc/tasks/assistant-eval.md §E8
溫度掃描 (think:false · 4 溫 × 10)	\$4	temp_sweep_20260708T135541Z.md
溫度掃描 (thinking enabled · 4 溫 × 5)	\$4	temp_sweep_20260708T165846Z.md
多輪記憶 (2 案例 · 10/10)	\$5	temp_sweep_20260707T173641Z.md
多輪記憶 (3 案例 · recall 0/5)	\$5	temp_sweep_20260708T034239Z.md
多輪記憶 (recall 修復後 · 5/5)	\$5	temp_sweep_20260709T011132Z.md

註：eval/out/ 為 gitignored 原始輸出；正式交接時建議另行保存與文件版本對應的原始結果。

附錄 D：參考資料

以下資料用於說明本文件的設計依據與工程背景；本文件並非完整文獻回顧。

參考資料	用途	URL
Qianyu Meng, Yanan Wang, Liyi Chen, Qimeng Wang, Chengqiang Lu, Wei Wu, Yan Gao, Yi Wu, Yao Hu. Agent Harness for Large Language Model Agents: A Survey. Preprints, 2026.	用於 Agent Harness 六元件定義與 H=(E,T,C,S,L,V) 架構對應。	https://www.preprints.org/manuscript/202604.0428
Yilun Yao et al. Harness-Bench: Measuring Harness Effects across Models in Realistic Agent Workflows. arXiv:2605.27922, 2026.	用於 model-harness configuration 評估觀點。	https://arxiv.org/abs/2605.27922
LangChain. How to Debug & Evaluate AI Agents with Observability. 2026.	用於 trace、observability 與 eval 閉環之工程背景。	https://www.langchain.com/blog/agent-observability-powers-agent-evaluation
Function Calling / Tool Use reference (工程參考影片與官方文件)	用於結構化 tool / skill invocation 概念。	https://www.youtube.com/watch?v=bvmDriP7kbw https://developers.openai.com/api/docs/guides/function-calling